
Analyse du comportement d'achat des clients à l'aide des données Instacart

Rapport

Encadré par Monsieur M. El Machkouri et M. Ouassou

Membres du groupe

Email

Assmaa BAMAAROUF	Assmaa.BAMAAROUF@emines.um6p.ma
Aya KAMOUNI	Aya.KAMOUNI@emines.um6p.ma
Najma ATCHANY	Najma.ATCHANY@emines.um6p.ma
Rachid AIT JALLOUL	Rachid.AITJALLOUL@emines.um6p.ma



May 12, 2025

Table of Contents

1	Résumé	3
2	Introduction	4
3	Vue d'ensemble du projet	4
4	Structure de données	4
5	Statistiques Descriptives	5
5.1	Tendances des achats	5
5.2	Tendances des achats	7
5.2.1	Les allées les plus fréquentées	7
5.2.2	Le nombre de produit par commande	9
5.2.3	la répartition temporelle des achats	10
5.3	Tendance des réachats	10
5.3.1	Taux de réachat par département	12
5.3.2	Taux de réachat par allée	12
5.3.3	L'effet de la position du produit dans le chariot sur le ratio de réachat	14
5.4	Fréquence des commandes	14
6	Segmentation des clients	16
6.1	Préparation des données	16
6.2	Réduction des données par ACP	17
6.3	Détermination du nombre optimal de segments	18
6.4	Segmentation clients et tests d'hypothèse	19
6.5	Analyse statistique des clusters – Test t de Student	21
6.5.1	Explication statistique du test t de Student	21
7	Analyse du panier d'achats	24
7.1	Les étapes principales de l'algorithme sont :	25
8	Modélisation prédictive	29
8.1	Pré-traitement des données	29
8.1.1	Variables au niveau de l'utilisateur	30
8.1.2	Variables au niveau du produit	31
8.1.3	Variables utilisateur-produit (interactions)	31
8.2	Analyse de la variable cible	31
8.3	Modèles de prediction:	32
8.3.1	Métriques d'évaluation des modèles de classification	32
8.3.2	Régression logistique	34
8.3.3	Modèle Logistique	36
8.3.4	Random Forest	37
8.3.5	XGBoost (Extreme Gradient Boosting)	39
8.3.6	4. Naive Bayes	41

List of Figures

1	Le pourcentage des achats par département	6
2	Le pourcentage des produits par département	6
3	Les allées les plus fréquentées	8
4	Le nombre de produit par commande	9
5	La répartition temporelle des achats	10
6	Le pourcentage des achats par département	10
7	Le pourcentage des produits par département	10
8	La répartition temporelle des achats	11
9	<i>Taux de réachat par département</i>	12
10	<i>Taux de réachat par allée</i>	13
11	<i>Moyenne de réachat par jour et heure</i>	13
12	<i>L'effet de la position du produit dans le chariot sur le ratio de réachat</i>	14
13	<i>Taux de réachat par allée</i>	15
14	<i>Taux de réachat par allée</i>	16
15	<i>Variance expliquée par les composantes principales</i>	17
16	<i>Elbow Method</i>	19
17	<i>Segmentation des clients à l'aide de l'ACP et de K-means</i>	20
18	<i>diagramme de sankey des règles d'association</i>	26
19	<i>Diagramme de Sankey des règles d'association</i>	27
20	<i>Diagramme de Sankey des règles d'association</i>	28
21	<i>Importance des variables Random Forest</i>	38
22	<i>Scores d'importance des variables</i>	40

List of Tables

1	Comparaison des profils d'acheteurs selon différents clusters	20
3	Interprétation des tailles d'effet selon Cohen's d	23
4	Résultats pour la variable <code>days_since_prior_order</code>	23
5	Résultats pour la variable <code>unique_aisles</code>	23
6	Résultats pour la variable <code>favorite_aisle_orders</code>	24
7	Valeurs du VIF pour chaque variable explicative	35
8	Résumé des coefficients du modèle de régression logistique	36
9	Performance de la régression logitistique	37
10	Performance du modèle Random Forest	39
11	Performance du modèle XGBoost	41
12	Performance du modèle Naive Bayes	42
13	Comparaison des performances des modèles	43

1 Résumé

Ce projet se concentre sur l'analyse du comportement d'achat à partir du jeu de données Instacart Market Basket. L'étude combine une analyse exploratoire approfondie (EDA), une segmentation fine de la clientèle basée sur des caractéristiques comportementales et une analyse des paniers d'achat par la méthode des règles d'association. De plus, une stratégie de modélisation prédictive est proposée pour anticiper les produits susceptibles d'être recommandés, tout en évoquant les enjeux de scalabilité et l'implémentation sur des plateformes distribuées. L'objectif global est d'améliorer la pertinence des recommandations produits et d'optimiser l'expérience utilisateur dans un environnement de commerce en ligne.

2 Introduction

Dans un marché de plus en plus compétitif, comprendre et anticiper les schémas d'achat des consommateurs est devenu crucial pour optimiser les stratégies marketing et personnaliser l'expérience utilisateur. Le présent projet exploite le jeu de données Instacart Market Basket afin de :

3 Vue d'ensemble du projet

Ce projet a pour objectif d'explorer les comportements d'achat des utilisateurs de la plateforme **Instacart**, un service de livraison de courses en ligne. En analysant les données issues des paniers d'achat des clients, nous cherchons à :

- Identifier des produits d'achats fréquents,
- Comprendre les préférences des consommateurs,
- Découvrir des associations entre produits,
- Améliorer les recommandations ou la stratégie marketing.

Le projet s'articule autour de plusieurs axes :

- Nettoyage et structuration des données
- Analyse descriptive (produits populaires, récurrence d'achats, comportements par jour/heure. . .)
- Détection de règles d'association entre produits
- Construction d'un modèle prédictif pour anticiper les futurs achats d'un utilisateur

4 Structure de données

Les données proviennent du jeu *Instacart Market Basket Analysis* disponible sur Kaggle, et sont réparties dans plusieurs fichiers :

- `aisles.csv` : contient les identifiants et noms des allées de supermarché.
- `departments.csv` : liste les grands départements regroupant les allées avec leur ID.
- `products.csv` : associe chaque produit à son nom, à une allée et un département.
- `orders.csv` : enregistre les commandes passées par les clients, avec des informations temporelles (jour de la semaine, heure, délai depuis la commande précédente).
- `order_products__prior.csv` et `order_products__train.csv` : listent les produits de chaque commande, précisent l'ordre d'ajout au panier et indiquent si un produit a été déjà commandé.

5 Statistiques Descriptives

NB : Pour visualiser et interpréter notre base de données, nous avons créé une seule **dataframe** fusionnant toutes les données issues des différents fichiers CSV :

```
(order_id, product_id, add_to_cart_order, reordered, user_id, order_number, order_dow,
order_hour_of_day, days_since_prior_order, product_name, aisle_id, department_id,
aisle, department)
```

Étant donné la taille énorme de notre base de données (environ 3.38×10^7 enregistrements), nous avons choisi d'exploiter notre base petit à petit, en explorant tout d'abord les tendances d'achats au niveau des **départements**, puis des **allées**, pour arriver finalement aux **produits**.

5.1 Tendances des achats

Comprendre comment les clients interagissent avec les différentes catégories de produits est essentiel pour :

- Identifier les axes de fidélisation,
- Détecter les opportunités de recommandation,
- Mettre en évidence les tendances comportementales dominantes.

Cette analyse se concentre donc sur la popularité et la récurrence des achats au niveau des **départements** et des **allées**.




Figure 1: Le pourcentage des achats par département




Figure 2: Le pourcentage des produits par département

Produce (Fruits et légumes) :

- Représente 29% des achats, mais probablement moins en nombre de produits.
- Cela signifie que peu de produits génèrent beaucoup d'achats : ce sont des produits essentiels et fréquents, achetés presque systématiquement.

Personal care (Soins personnels) :

- Représente 13% des produits, mais probablement peu d'achats.
- Ce sont des produits nombreux mais achetés moins fréquemment : dentifrice, shampo-

ing, etc. → non-alimentaire, non-récurrent.

Pantry (Épicerie sèche) :

- Représente 11 % des produits mais seulement 6 % des achats.
- Large choix, mais pas forcément des achats fréquents (produits de longue conservation).

Dairy, eggs, snacks, beverages, frozen :

- Ces départements ont une représentation équilibrée en nombre de produits et d'achats, ce qui indique des achats réguliers avec une bonne diversité d'offre.

5.2 Tendances des achats

Comprendre comment les clients interagissent avec les différentes catégories de produits est essentiel pour :

- Identifier les axes de fidélisation,
- Détecter les opportunités de recommandation,
- Mettre en évidence les tendances comportementales dominantes.

Cette analyse se concentre donc sur la popularité et la récurrence des achats au niveau des **départements** et des **allées**.

- Décrypter les comportements d'achat à travers l'analyse du cycle de commande
- Segmenter la clientèle en groupes homogènes, permettant ainsi de mieux cibler les recommandations
- Identifier les associations fréquentes entre les produits
- Mettre en place une stratégie de prédiction du réachat d'articles via un modèle prédictif évolutif

5.2.1 Les allées les plus fréquentées

Pour raffiner l'analyse, nous avons examiné les achats au niveau des allées, tout en gardant l'information du département. Cela permet d'identifier les zones de performance dans chaque catégorie




Figure 3: Les allées les plus fréquentées

On constate alors que même s'il y a beaucoup d'allées, la majorité des achats est concentrée sur une vingtaine d'entre elles (fresh fruits, fresh vegetables, yogurt...). Cela indique que le comportement d'achat est dirigé vers certains produits essentiels et récurrents, conformément au graphe précédent.

5.2.2 Le nombre de produit par commande




Figure 4: *Le nombre de produit par commande*

La distribution de la courbe est asymétrique à droite, avec un pic situé entre 5 et 10 produits par commande, ce qui indique que la plupart des commandes contiennent entre 5 et 15 articles. Les commandes très volumineuses (plus de 40 produits) sont rares. Les clients ont donc tendance à effectuer des achats de taille moyenne. Cette observation peut être exploitée pour :

- Optimiser l'interface de commande, par exemple en ajustant le nombre de lignes affichées par défaut.
- Adapter les recommandations, en proposant des packs de produits correspondant à cette taille moyenne (entre 5 et 15 produits).

5.2.3 la répartition temporelle des achats




Figure 5: *La répartition temporelle des achats*

Les achats sont majoritairement effectués entre 8h et 19h, ce qui est cohérent avec les habitudes quotidiennes. On observe également une forte concentration des commandes le week-end, en particulier entre 9h et 16h.

L'objectif du projet est de recommander des produits susceptibles d'être achetés par l'utilisateur. Il ne suffit donc pas de se baser uniquement sur les produits achetés, mais aussi sur ceux qui ont été rachetés. En effet, ce paramètre reflète davantage la fidélité de l'utilisateur envers un produit donné. Il est donc essentiel d'analyser également cet indicateur dans la suite du projet.

5.3 Tendence des réachats

NB : On veut dire par réachat le fait qu'un client achète le même produit plus qu'une fois. Explorant tout d'abord quelques informations générales sur les produits rachetés:




Figure 6: *Le pourcentage des achats par département*




Figure 7: *Le pourcentage des produits par département*




Figure 8: *La répartition temporelle des achats*

Interprétation : L'analyse révèle que le réachat domine à l'échelle produit, avec des articles plus souvent rachetés qu'achetés pour la première fois (Fig. 6), traduisant des habitudes bien ancrées. La majorité des commandes incluent au moins un produit familier (Fig. 8), mais ne sont pas exclusivement composées de réachats : seules 22–23 % sont des paniers de pur réapprovisionnement (Fig. 7). Ainsi, environ 70 % des commandes combinent produits connus et nouveautés, montrant un comportement d'achat équilibré entre fidélité et exploration. Les commandes 100 % découvertes restent rares (7–8 %).

Méthodologie

Pour chaque produit, nous avons calculé :

- Le nombre total d'achats
- Le nombre de réachats (produits marqués `reordered` = 1)
- Le taux de réachat, défini comme :

$$\text{Taux de réachat} = \frac{\text{Nombre de réachats}}{\text{Nombre total d'achats}}$$

Ensuite, nous avons agrégé ces valeurs par département, puis par allée.

5.3.1 Taux de réachat par département




Figure 9: *Taux de réachat par département*

Les données montrent une forte tendance au réachat pour les produits de consommation rapide, frais et essentiels comme les **produits laitiers et œufs**, **boissons**, **fruits et légumes**, et **boulangerie**. Ces rayons présentent les taux de réachat les plus élevés (environ 63 % à 68 %), traduisant une forte fidélité des clients et une consommation fréquente.

À l'inverse, des rayons comme **soins personnels**, **épicerie sèche (pantry)** ou **produits internationaux** affichent des taux de réachat faibles (autour de 32 % à 38 %), ce qui reflète des achats plus espacés dans le temps, souvent liés à la longue durée de vie des produits. Cette tendance est également cohérente avec leur faible part dans le volume d'achats, malgré une diversité de produits plus élevée.

5.3.2 Taux de réachat par allée

Pour affiner l'analyse du réachat, nous avons examiné les taux de réachat au niveau des allées, de manière identique à l'analyse des achats.




Figure 10: Taux de réachat par allée

Même avec un graphique plus détaillé, les mêmes tendances demeurent évidentes.




Figure 11: Moyenne de réachat par jour et heure

Les taux de réachat les plus élevés se concentrent clairement entre 6h et 9h du matin, toutes journées confondues. Cela peut refléter une habitude d'achat matinale, notamment pour les courses de réapprovisionnement.

Le lundi (jour 1) enregistre le pic le plus élevé de réachats, surtout vers 7h-8h, ce qui peut s'expliquer par une volonté de réapprovisionner le début de semaine. Les autres jours, notamment du mercredi au dimanche, affichent des comportements plus stables et moins in-

tenses.

5.3.3 L'effet de la position du produit dans le chariot sur le ratio de réachat




Figure 12: *L'effet de la position du produit dans le chariot sur le ratio de réachat*

Les premières positions dans le panier contiennent souvent les produits les plus régulièrement recommandés, probablement parce que ce sont des produits favoris ou de consommation fréquente.

La baisse de la probabilité de recommandation à mesure que la position augmente est probablement due à deux facteurs :

- Les produits en fin de liste sont moins prioritaires ou moins fréquents.
- Les commandes longues sont rares, donc les données pour les positions élevées sont moins fiables (ce qui explique les fluctuations et les zéros à partir de la position 100).

Le bruit dans les dernières positions est dû à un faible nombre de cas observés à ces positions.

5.4 Fréquence des commandes

Parmi les paramètres indiqués dans notre data, on trouve le `days_since_prior_order` qui indique le nombre de jours depuis la commande précédente d'un client. Cette variable prend Nan s'il s'agit d'une première commande d'un client. Alors, pour arriver à la visualiser, nous avons donné à ces derniers la valeur de -1.




Figure 13: *Taux de réachat par allée*

L'analyse du graphique met en évidence deux grands comportements d'achat. D'abord, un volume élevé de premières commandes (valeur -1) confirme que chaque client entre naturellement dans le système par une commande initiale. Ensuite, une forte concentration de réachats dans les 7 jours suivant une commande précédente, avec un pic notable au 7 jours, suggère un cycle hebdomadaire dans une grande partie des commandes. Au-delà de ce seuil, les achats deviennent plus espacés, traduisant une baisse progressive d'activité. Enfin, un nouveau pic au 30 jours révèle l'existence d'un autre segment des achats qui sont faits d'un rythme mensuel.

Cependant, il est important de noter que ce graphique reflète uniquement la répartition des commandes d'une façon générale, sans les distinguer par client. Par conséquent, il ne permet pas de caractériser précisément les comportements d'achat des clients à un niveau individuel.




Figure 14: *Taux de réachat par allée*

L'analyse révèle que la majorité des clients ont une fréquence moyenne d'achat située entre 7 et 15 jours, ce qui suggère un comportement régulier, avec des achats effectués toutes les 1 à 2 semaines. Le pic observé autour de 10 à 11 jours indique un rythme bi-hebdomadaire dominant. Au-delà de 15 jours, la fréquence moyenne diminue progressivement, montrant que les clients occasionnels sont nettement moins nombreux. Néanmoins, un léger pic à 30 jours laisse apparaître un segment fidèle à un cycle d'achat mensuel. À l'inverse, très peu de clients achètent plusieurs fois par semaine, comme le montre la faible densité en dessous de 4 jours.

6 Segmentation des clients

6.1 Préparation des données

Afin de construire des profils utilisateurs pertinents en vue d'une analyse par ACP, nous avons agrégé plusieurs indicateurs comportementaux à partir des données transactionnelles. Tout d'abord, nous avons calculé pour chaque utilisateur la moyenne du temps écoulé entre deux commandes successives (`days_since_prior_order`) ainsi que son taux moyen de réachat (`reordered`), ce dernier indiquant la tendance d'un utilisateur à commander de nouveau les mêmes produits.

Ensuite, nous avons analysé les préférences en matière de rayons (*aisles*) en identifiant, pour chaque utilisateur, le rayon le plus fréquemment commandé, ainsi que le nombre total de commandes dans ce rayon. Par ailleurs, la diversité des achats a été mesurée à travers le nombre de rayons distincts visités par utilisateur.

Toutes ces informations ont ensuite été fusionnées dans une seule table synthétique, où chaque ligne représente un utilisateur décrit par des caractéristiques comportementales résumées.

6.2 Réduction des données par ACP

Dans le but de réduire la dimensionnalité de nos données utilisateurs tout en conservant l'essentiel de l'information, nous avons appliqué une Analyse en Composantes Principales (ACP). Cette méthode commence par une standardisation des variables explicatives à l'aide du `StandardScaler`, ce qui garantit que chaque variable ait une moyenne nulle et un écart type de 1. Cette étape est essentielle puisque l'ACP est sensible aux différences d'échelle entre variables. La matrice standardisée

$$X \in \mathbb{R}^{n \times p}$$

où n est le nombre d'utilisateurs et p le nombre de variables comportementales, est ensuite transformée par la méthode ACP.

Mathématiquement, l'ACP consiste à effectuer une décomposition en valeurs propres de la matrice de covariance

$$\Sigma = \frac{1}{n-1} X^\top X$$

Les vecteurs propres (ou composantes principales) $v_1, v_2, \dots, v_p$ sont les nouvelles directions de l'espace maximisant la variance des données, et les valeurs propres associées

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$$

quantifient la part de variance expliquée par chaque direction. Nous avons retenu ici les deux premières composantes principales PC_1 et PC_2 , qui permettent une représentation visuelle bidimensionnelle des utilisateurs tout en capturant une grande partie de la variabilité initiale.




Figure 15: *Variance expliquée par les composantes principales*

Composante 1 : 54.27 % de la variance expliquée
Composante 2 : 19.04 % de la variance expliquée
Variance cumulée (2 composantes) : 73.31 %

6.3 Détermination du nombre optimal de segments

Après la réduction de dimension par l'ACP, nous avons appliqué l'algorithme de classification non supervisée *K-means* sur les données standardisées afin de segmenter les utilisateurs en groupes homogènes. L'algorithme *K-means* cherche à partitionner les observations en K clusters en minimisant la somme des distances quadratiques intra-clusters, aussi appelée inertie intra-classe ou *Within-Cluster Sum of Squares (WCSS)*. Mathématiquement, pour un nombre de clusters K , l'objectif est de minimiser :

$$\text{Inertie}(K) = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

Où C_k est le k -ième cluster et $\boldsymbol{\mu}_k$ son centroïde. Plus K augmente, plus l'inertie diminue, car les points sont plus proches des centroïdes. Cependant, augmenter indéfiniment K conduit à un surajustement.

Pour choisir une valeur optimale de K , nous avons utilisé la méthode du coude : elle consiste à tracer l'inertie en fonction du nombre de clusters K . On cherche alors un point de rupture ou coude, à partir duquel l'ajout de nouveaux clusters n'apporte qu'une réduction marginale de l'inertie. Ce point correspond généralement au bon compromis entre homogénéité des clusters et complexité du modèle.

Dans notre cas, la courbe obtenue permet d'identifier visuellement ce point de coude, qui oriente le choix optimal du nombre de clusters à utiliser pour la segmentation client.




Figure 16: *Elbow Method*

6.4 Segmentation clients et tests d'hypothèse

Après avoir déterminé le nombre optimal de groupes à l'aide de la méthode du coude, nous avons segmenté les utilisateurs en $K = 3$ clusters à l'aide de l'algorithme ***K-means***, appliqué aux données projetées sur les deux premières composantes principales issues de l'ACP. En utilisant ces composantes, nous bénéficions d'une représentation réduite et débruitée de l'information, tout en conservant l'essentiel de la variabilité des comportements utilisateurs.

La segmentation obtenue est visualisée par **un nuage de points dans le plan (PC1, PC2)**, où chaque point représente un utilisateur et est coloré selon le cluster auquel il appartient. Cette représentation facilite l'interprétation : des regroupements nets indiquent une bonne séparation des comportements utilisateurs.




Figure 17: *Segmentation des clients à l'aide de l'ACP et de K-means*

Table 1: *Comparaison des profils d'acheteurs selon différents clusters*

Cluster	Utilisateurs	Freq. (j)	% Réachat	Cmds rayon	Rayons
Cluster 1 : Acheteurs réguliers et modérés	77 984	~10	~47.7 %	~19	~22
Cluster 2 : Clients occasionnels et peu fidèles	86 508	~18.3	~31.3 %	~12.7	~24.5
Cluster 3 : Clients fidèles et très actifs	41 717	~9	~65.7 %	~83	~49

Interprétation des clusters

Cluster 1 — Acheteurs réguliers : Ce groupe rassemble des clients qui commandent en moyenne tous les 10 jours, avec une fidélité modérée (près de la moitié des produits sont rachetés). Leur comportement révèle un panier relativement stable, associé à une diversité modérée. Ces utilisateurs semblent bien familiarisés avec la plateforme, adoptant un comportement cohérent sans pour autant être strictement attachés à un assortiment particulier.

Cluster 2 — Acheteurs occasionnels : Ces clients commandent environ une fois toutes les deux à trois semaines, avec un faible taux de réachat. Cela peut traduire une instabilité dans leurs préférences ou un comportement exploratoire. Malgré cela, leur diversité d'achat est comparable,

voire légèrement supérieure à celle des réguliers, suggérant qu'ils parcourent plusieurs rayons sans véritable fidélité.

Cluster 3 — Acheteurs intensifs : Ce segment correspond aux clients les plus engagés et fidèles. Ils commandent fréquemment (presque chaque semaine), rachètent systématiquement leurs produits favoris, et explorent un large éventail de rayons. Le nombre très élevé de commandes dans leur rayon favori témoigne d'une forte spécialisation ou d'un attachement particulier à certains produits. Ce groupe constitue une base client précieuse avec un fort potentiel de rétention.

6.5 Analyse statistique des clusters – Test t de Student

Afin d'évaluer si les différences observées entre les trois clusters sont statistiquement significatives, nous avons appliqué le test t de Student pour échantillons indépendants (version de Welch, qui ne suppose pas l'égalité des variances). Ce test a été réalisé sur les variables suivantes :

- **days_since_prior_order** (nombre de jours entre deux commandes),
- **unique_aisles** (nombre de rayons distincts commandés),
- **favorite_aisle_orders** (nombre de commandes passées dans le rayon préféré),
- **reordered** (taux de réachat).

6.5.1 Explication statistique du test t de Student

Le test t de Student permet de comparer les moyennes de deux groupes indépendants. Il repose sur l'idée que, si deux groupes sont issus d'une même population, alors la différence de leurs moyennes devrait être faible relativement à la variabilité observée dans les données. Le test calcule une statistique t selon la formule suivante (version de Welch) : La statistique de test t utilisée pour comparer les moyennes de deux échantillons indépendants est donnée par :

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

où :

- $\bar{X}_1$ et $\bar{X}_2$ sont les moyennes des deux échantillons,
- s_1^2 et s_2^2 sont les variances des deux échantillons,
- n_1 et n_2 sont les tailles des deux échantillons.

La p -value obtenue quantifie la probabilité d'observer une telle différence de moyennes (ou une différence plus extrême) si les deux groupes provenaient en réalité de la même distribution (hypothèse nulle H_0).

- Si $p < 0,05$, on rejette H_0 et on conclut que la différence est statistiquement significative.

- Si $p \geq 0,05$, on ne rejette pas H_0 .

Comparaison	Variable	t-statistic	p-value
Cluster 1 vs Cluster 2	days_since_prior_order	-444.86	< 0.001
Cluster 2 vs Cluster 3	days_since_prior_order	429.22	< 0.001
Cluster 3 vs Cluster 1	days_since_prior_order	-46.44	< 0.001
Cluster 1 vs Cluster 2	unique_aisles	-37.85	< 0.001
Cluster 2 vs Cluster 3	unique_aisles	-317.82	< 0.001
Cluster 3 vs Cluster 1	unique_aisles	348.34	< 0.001
Cluster 1 vs Cluster 2	favorite_aisle_orders	114.15	< 0.001
Cluster 2 vs Cluster 3	favorite_aisle_orders	-246.11	< 0.001
Cluster 3 vs Cluster 1	favorite_aisle_orders	220.69	< 0.001
Cluster 1 vs Cluster 2	reordered	195.26	< 0.001
Cluster 2 vs Cluster 3	reordered	-428.08	< 0.001
Cluster 3 vs Cluster 1	reordered	201.58	< 0.001

Conclusion :

Ces écarts étant statistiquement significatifs, ils confirment la pertinence des segments formés et permettent d'envisager des stratégies de personnalisation ou de ciblage différenciées selon les profils. Même si avec un grand nombre de données, le test t détecte des différences statistiquement significatives qui ne sont pas forcément pertinentes ou importantes en pratique. Une fois que l'on a effectué un t-test et que l'on a trouvé une différence statistiquement significative entre les groupes, Cohen's d peut être calculé pour évaluer l'ampleur de cette différence, indépendamment de la taille de l'échantillon.

Cohen's d se calcule comme suit pour un t-test pour échantillons indépendants :

$$d = \frac{M_1 - M_2}{\sigma_p}$$

Où :

- M_1 et M_2 sont les moyennes des groupes.
- σ_p est l'écart-type combiné des deux groupes, calculé par :

$$\sigma_p = \sqrt{\frac{(n_1 - 1) \cdot s_1^2 + (n_2 - 1) \cdot s_2^2}{n_1 + n_2 - 2}}$$

Où :

- s_1 et s_2 sont les écarts-types des groupes 1 et 2.
- n_1 et n_2 sont les tailles des groupes 1 et 2.

Table 3: Interprétation des tailles d'effet selon Cohen's d

Cohen's d	Interprétation
0.0 – 0.19	Négligeable
0.2 – 0.49	Petite taille d'effet
0.5 – 0.79	Taille d'effet moyenne
0.8 – 1.29	Grande taille d'effet
≥ 1.3	Très grande taille d'effet (rare)

Analyse de la variable `days_since_prior_order` Concernant la variable `days_since_prior_order`, les comparaisons entre clusters montrent des tailles d'effet très importantes entre les clusters 1 et 2 ($d = -2,20$) ainsi qu'entre les clusters 2 et 3 ($d = 2,53$), ce qui indique des différences nettes dans les habitudes de fréquence d'achat. En revanche, la différence entre les clusters 3 et 1 est beaucoup plus modérée ($d = -0,28$), ce qui suggère une similarité relative entre ces deux groupes.

Table 4: Résultats pour la variable `days_since_prior_order`

Comparaison	t-statistic	p-value	Cohen's d	Interprétation
Cluster 1 vs Cluster 2	-444.86	0.0000	-2.20	Très grande
Cluster 2 vs Cluster 3	429.22	0.0000	2.53	Très grande
Cluster 3 vs Cluster 1	-46.44	0.0000	-0.28	Petite

Analyse de la variable `unique_aisles` Pour la variable `unique_aisles`, qui reflète la diversité des rayons visités, les tailles d'effet varient : la comparaison entre les clusters 2 et 3 révèle une très grande différence ($d = -1,93$), tout comme celle entre les clusters 3 et 1 ($d = 2,17$). En revanche, la différence entre les clusters 1 et 2 est faible ($d = -0,19$), ce qui peut indiquer une similarité dans la variété des achats entre ces deux groupes.

Table 5: Résultats pour la variable `unique_aisles`

Comparaison	t-statistic	p-value	Cohen's d	Interprétation
Cluster 1 vs Cluster 2	-37.85	0.0000	-0.19	Négligeable
Cluster 2 vs Cluster 3	-317.82	0.0000	-1.93	Très grande
Cluster 3 vs Cluster 1	348.34	0.0000	2.17	Très grande

Analyse de la variable `favorite_aisle_orders` En ce qui concerne `favorite_aisle_orders`, les résultats indiquent une taille d'effet moyenne entre les clusters 1 et 2 ($d = 0,57$), mais très importante entre les clusters 2 et 3 ($d = -1,69$) ainsi qu'entre les clusters 3 et 1 ($d = 1,51$). Cela suggère que les préférences pour un rayon dominant sont particulièrement marquées dans certains groupes.

Table 6: Résultats pour la variable *favorite_aisle_orders*

Comparaison	t-statistic	p-value	Cohen's d	Interprétation
Cluster 1 vs Cluster 2	114.15	0.0000	0.57	Moyenne
Cluster 2 vs Cluster 3	-246.11	0.0000	-1.69	Très grande
Cluster 3 vs Cluster 1	220.69	0.0000	1.51	Très grande

Enfin, pour la variable *reordered*, qui mesure la propension à racheter les mêmes produits, les tailles d'effet sont également fortes à très fortes : moyenne entre les clusters 1 et 2 ($d = 0,97$), très importante entre les clusters 2 et 3 ($d = -2,45$), et grande entre les clusters 3 et 1 ($d = 1,15$). Ces résultats montrent que les habitudes de réachat varient de manière substantielle entre les clusters.

7 Analyse du panier d'achats

Le *market basket analysis* est une méthode statistique utilisée en marketing pour identifier des associations ou des corrélations entre les articles achetés ensemble. Elle permet de répondre à des questions comme :

- « Si un client achète du pain, est-il aussi susceptible d'acheter du beurre ? »
- « Quels produits sont souvent achetés ensemble ? »

Parmi les algorithmes largement utilisés pour faire la détection des associations, on trouve l'algorithme apriori.

Pour comprendre le fonctionnement de ce dernier, on doit tout d'abord donner la définition des mots-clés suivants :

- Un *itemset* est un ensemble d'articles (par exemple : {pain, beurre}) qui apparaissent ensemble dans une ou plusieurs transactions.
- Le *support* d'un itemset correspond à la fréquence d'apparition de cet ensemble dans les transactions :

$$\text{Support}(A) = \frac{\text{Nombre de transactions contenant } A}{\text{Nombre total de transactions}}$$

Par exemple, un support de 0,05 signifie que l'itemset apparaît dans 5% des transactions.

- Le *support minimal* (*min_support*) est le seuil au-dessous duquel un itemset est considéré comme non pertinent. Ce filtre permet de réduire la complexité et d'éliminer les combinaisons rares. (Dans notre application de l'algorithme Apriori, nous avons fixé le seuil de support minimal à 0,001 (0,1%). Ce choix est justifié par le fait que le volume de données est extrêmement important, avec plus de $3,38 \times 10$ transactions. Dans un tel contexte, un seuil de support trop élevé risquerait d'éliminer des règles intéressantes, notamment celles concernant des produits moins fréquents mais potentiellement pertinents. De plus, un *min_support* de 0,001 signifie que nous considérons comme intéressants tous les ensembles d'articles présents dans au moins 0,1% des transactions, soit environ 33 800 occurrences.)

7.1 Les étapes principales de l'algorithme sont :

1. **Préparation des transactions** : chaque transaction est représentée comme une liste d'articles achetés ensemble.
2. **Calcul des itemsets fréquents** :
 - On commence par les articles individuels (itemsets de taille 1).
 - Ensuite, on génère des combinaisons d'articles (itemsets de taille 2, 3, ...).
 - À chaque étape, on conserve uniquement les combinaisons dont le support dépasse le support minimal.
3. **Génération de la règle d'association** : À partir des itemsets fréquents, on génère la règle d'association $A \Rightarrow B$ qui signifie : si A est acheté, alors B est probablement acheté.
4. **Évaluation** : cette règle est évaluée à l'aide de mesures de qualité comme :

- **Support** : Proportion de transactions contenant à la fois A et B.

$$Support(A \cup B) = \frac{\text{Transactions contenant A et B}}{\text{Nombre total de transactions}}$$

- **Confiance (Confidence)** : Probabilité d'achat de B sachant que A a été acheté.

$$Confidence(A \Rightarrow B) = \frac{Support(A \cup B)}{Support(A)} = P(B | A)$$

- **Lift** : Indique si l'occurrence de B est indépendante de A.

$$Lift(A \Rightarrow B) = \frac{Confidence(A \Rightarrow B)}{Support(B)}$$

- $Lift > 1$: corrélation positive, A et B apparaissent ensemble plus souvent que prévu par le hasard.
- $Lift = 1$: indépendance, A et B sont statistiquement indépendants.
- $Lift < 1$: corrélation négative, A et B apparaissent ensemble moins souvent que prévu.


Dans notre analyse des règles d'association, nous avons retenu la métrique "confiance" comme critère principal, avec un seuil minimal fixé à 0,5 (50%). Ce choix repose sur le fait que la confiance mesure la probabilité qu'un produit soit acheté lorsqu'un autre l'est également, ce qui en fait un indicateur à la fois simple, pertinent et directement exploitable dans un contexte commercial (recommandation, vente croisée, organisation des rayons, etc.).

En fixant ce seuil à 0,5, nous avons cherché à extraire des règles solides, dans lesquelles le produit conséquence apparaît dans au moins 50% des cas où l'antécédent est présent. Cela permet d'écarter les règles faibles ou dues au hasard, tout en conservant un nombre raisonnable de règles exploitables.

Ce paramétrage est d'autant plus pertinent que notre base de données est très volumineuse. Il constitue ainsi un compromis équilibré entre qualité des règles et couverture statistique.

À l'issue de l'application de l'algorithme Apriori sur nos données transactionnelles, nous avons pu générer le diagramme de Sankey suivant, qui illustre les règles d'association extraites.

Diagramme de Sankey des règles d'association


Figure 18: *diagramme de sankey des règles d'association*

Structure du graphe

- **À gauche** : les antécédents (ensembles de produits achetés ensemble).
- **À droite** : les conséquents (produits souvent achetés en complément).
- **La largeur des flèches** : proportionnelle au support de la règle (fréquence relative dans le dataset).
- **Chaque couleur** représente un groupe différent d'antécédents.

L'analyse initiale de ce diagramme révèle que les produits frais, notamment les fruits et légumes, dominent largement les associations observées. Cela s'explique par leur forte fréquence dans les commandes : une proportion très importante des transactions contient au moins un de ces produits. Par conséquent, ces articles agissent comme des pivots transactionnels, limitant la visibilité d'autres associations potentiellement intéressantes.

Pour élargir la portée de notre exploration, nous avons choisi de travailler sur un sous-échantillon représentatif de 10000 utilisateurs, tout en conservant la richesse comportementale du jeu de données. Cette étape vise à :

- Réduire la dominance statistique des catégories ultra-fréquentes ;
- Dégager de nouvelles règles d'association à travers un prisme plus équilibré ;
- Rendre les visualisations plus lisibles et exploitables.

Diagramme de Sankey des règles d'association




Figure 19: *Diagramme de Sankey des règles d'association*

Dans cette seconde visualisation par graphe de Sankey, l'analyse gagne en précision en passant des grandes allées aux produits spécifiques. Contrairement au graphe initial dominé visuellement par les catégories très larges comme « fresh fruits » et « fresh vegetables » – du fait d'un volume massif de données –, cette version réduite atténue l'effet d'écrasement de ces classes majoritaires et permet de révéler des règles d'association plus fines entre produits concrets, tels que le « Fat Free Blueberry Yogurt » ou encore le « Sparkling Water Grapefruit ». La granularité obtenue rend la visualisation bien plus exploitable, dévoilant des tendances de consommation précises comme des paniers orientés vers les produits bio, des associations fréquentes entre yaourts et fruits, ou encore des préférences autour des eaux aromatisées. En somme, ce graphe complète l'analyse macro en fournissant une lecture détaillée des habitudes concrètes des clients.

Diagramme de Sankey des règles d'association




Figure 20: Diagramme de Sankey des règles d'association

Analyse intermédiaire et consolidation des résultats

Dans un troisième temps, nous avons généré une **nouvelle version du graphe de Sankey**, cette fois à partir de **0,1 % des commandes totales** – soit près de **3,38 millions de transactions** –, afin de **combiner granularité produit et représentativité statistique**. Cette approche intermédiaire entre l'analyse globale et l'échantillon réduit des 10 000 utilisateurs permet de **consolider les observations précédentes** tout en révélant des **tendances plus robustes**.

La **structure du graphe** met en évidence des **associations produits plus stables**, notamment autour des **fruits les plus populaires comme les bananes**, fréquemment couplées à des **yaourts** ou des **produits bio**. D'autres groupes récurrents confirment l'émergence de **paniers orientés vers une consommation saine et naturelle**, avec des liens entre **avocats, œufs, concombres** ou encore **produits sans matières grasses**. Cette visualisation à plus grande échelle **renforce donc la fiabilité des règles d'association** en s'appuyant sur une **diversité de comportements d'achat bien plus représentative**.

Conclusion

À l'issue de cette **analyse approfondie du panier d'achats**, l'application de l'**algorithme Apriori** sur des jeux de données de différentes granularités a permis de dégager des **règles d'association cohérentes, robustes et exploitables**. En filtrant selon un **support minimal faible** et une **confiance élevée**, nous avons identifié plusieurs **familles d'associations produits récurrentes**.

Parmi les plus notables figurent les combinaisons de **fruits frais** comme **banane–pommes Fuji, raisins rouges–concombres**, ou encore **fraises–myrtilles**, témoignant d'un **intérêt marqué pour une alimentation naturelle**. Les **yaourts** constituent également un **nœud central** de plusieurs règles, notamment en association avec :

- des **fruits** (yaourt grec aux myrtilles avec fraises, bananes ou pêches),
- des **eaux aromatisées** (eau pétillante pamplemousse ou citron vert),
- d'autres **produits laitiers** (lait écrémé, lait d'amande).

D'autres groupes structurés émergent autour de **produits bio** (**avocats, œufs en plein air, légumes biologiques**), de **paniers sains** intégrant notamment **concombres, tomates, épinards** ou **yaourts sans matières grasses**, et même des **associations spécifiques** comme **pain complet–beurre de cacahuète** ou **crackers–fromage**.

Cette **richesse relationnelle entre produits** reflète des **logiques d'achat bien ancrées**, dont certaines relèvent d'**habitudes alimentaires** ou de **préférences diététiques**.

8 Modélisation prédictive

8.1 Pré-traitement des données

Afin d'entraîner les modèles de prédiction des produits susceptibles d'être rachetés, un travail de prétraitement et d'ingénierie des *features* a été réalisé. D'abord, des caractéristiques utilisateurs ont été extraites à partir de la table **orders**, en regroupant les données par utilisateur pour calculer le nombre total de commandes (**user_orders**), la période totale d'activité (**user_period**) et le délai moyen entre les commandes (**user_mean_days_since_prior**). Ensuite, les informations sur la taille des paniers (**basket_size**) ont été ajoutées, ainsi que des variables dérivées comme le nombre total de produits commandés, le nombre de produits re-commandés (i.e. ayant été achetés au moins une fois précédemment), et le ratio de réachat (**user_reorder_ratio**), ce dernier servant à quantifier la fidélité d'un utilisateur à ses habitudes de consommation. Des variables temporelles liées à la commande suivante ont également été intégrées (jour de la semaine et heure de commande).

Du côté des produits, plusieurs agrégats ont été calculés pour chaque `product_id`, tels que leur fréquence d'apparition (`prod_freq`), leur position moyenne dans le panier (`prod_avg_position`), leur taux de réachat (`prod_reorder_ratio`) ainsi que la fréquence moyenne avec laquelle les utilisateurs les commandent (`user_prod_avg_freq`). Enfin, des variables combinées utilisateur-produit ont été construites, incluant notamment le nombre de fois qu'un utilisateur a commandé un produit donné (`up_orders`), la position moyenne de ce produit dans son panier, l'ordre de la première et de la dernière commande, ainsi que des ratios comme le taux de commande d'un produit depuis la première commande ou depuis la dernière. Ces enrichissements ont permis de construire une matrice finale `data` rassemblant des indicateurs pertinents pour la tâche de classification, et une variable cible binaire indiquant si le produit a été racheté lors de la commande suivante.

8.1.1 Variables au niveau de l'utilisateur

Les données ont d'abord été agrégées par `user_id` afin de caractériser le comportement général d'achat de chaque utilisateur. Les variables suivantes ont été construites:

- **Nombre total de commandes passées par l'utilisateur :** $user_orders_u = \max(order_number)$
- **Période totale d'activité (en jours) :**

$$user_period_u = \sum days_since_prior_order$$

- **Moyenne des jours entre deux commandes :**

$$user_mean_days_since_prior_u = \frac{user_period_u}{user_orders_u - 1}$$

- **Nombre total de produits achetés :**

$$user_total_products_u = \sum 1$$

- **Nombre de produits rachetés :**

$$p_reordered_u = \sum 1_{reordered=1}$$

- **Nombre de commandes après la première :**

$$non_first_order_u = \sum 1_{order_number > 1}$$

- **Taux de réachat global :**

$$user_reorder_ratio_u = \frac{p_reordered_u}{non_first_order_u}$$

- **Taille moyenne du panier :**

$$user_average_basket_u = \frac{user_total_products_u}{user_orders_u}$$

Des variables temporelles concernant la prochaine commande (jour de la semaine, heure de commande, etc.) ont aussi été extraites.

8.1.2 Variables au niveau du produit

- **Fréquence d'achat du produit** : $prod_freq_p$ = nombre de fois où p a été commandé
- **Position moyenne dans le panier** :

$$prod_avg_position_p = \frac{1}{N_p} \sum add_to_cart_order$$

- **Taux de réachat (hors premières commandes)** :

$$prod_reorder_ratio_p = \frac{1}{N'_p} \sum reordered_{p,i}, \text{ avec } order_number_i > 1$$

- **Fréquence moyenne du produit par utilisateur** :

$$user_prod_avg_freq_p = \text{moyenne des commandes de } p \text{ par utilisateur}$$

8.1.3 Variables utilisateur-produit (interactions)

- **Nombre de commandes du produit par l'utilisateur** : Représente le nombre total de fois où l'utilisateur u a acheté le produit p .

$$up_orders(u, p) = \text{nombre de commandes de } p \text{ par } u$$

- **Première et dernière commande contenant le produit** :

$$up_first_order(u, p), \quad up_last_order(u, p)$$

- **Position moyenne dans le panier** :

$$up_average_cart_position(u, p) = \text{moyenne de } add_to_cart_order \text{ pour } p$$

- **Taux de commande du produit par l'utilisateur** :

$$up_order_rate(u, p) = \frac{up_orders(u, p)}{user_orders(u)}$$

- **Nombre de commandes depuis le dernier achat du produit** :

$$up_orders_since_last_order(u, p) = user_orders(u) - up_last_order(u, p)$$

- **Taux de commande du produit depuis sa première apparition** :

$$up_order_rate_since_first_order(u, p) = \frac{up_orders(u, p)}{user_orders(u) - up_first_order(u, p) + 1}$$

8.2 Analyse de la variable cible

Données complètes

- Nombre d'observations positives ($reordered = 1$) : 828 824
- Nombre d'observations négatives ($reordered = 0$) : 7 645 837
- Taux de produits rachetés : 9,78 %

Training Set (70 %)

- **Positifs** : 579 467
- **Négatifs** : 5 352 795
- **Taux de rachat** : 9,77 %

Testing Set (30 %)

- **Positifs** : 249 357
- **Négatifs** : 2 293 042
- **Taux de rachat** : 9,81 %

Le déséquilibre entre les classes a été préservé.

8.3 Modèles de prediction:

8.3.1 Métriques d'évaluation des modèles de classification

1. Accuracy (Exactitude)

L'accuracy mesure la proportion de prédictions correctes :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

où :

- **TP** : vrais positifs (produits rachetés correctement prédits),
- **TN** : vrais négatifs (produits non rachetés correctement prédits),
- **FP** : faux positifs (produits prédits rachetés mais ne l'étant pas),
- **FN** : faux négatifs (produits rachetés mais non prédits).

Elle donne une vue d'ensemble, mais peut être trompeuse si la classe des produits rachetés est rare.

2. Precision (Précision)

La précision mesure la proportion de prédictions positives correctes :

$$\text{Precision} = \frac{TP}{TP + FP}$$

Elle est utile pour évaluer la qualité des recommandations faites par le modèle, en minimisant les produits proposés à tort.

3. Recall (Rappel ou Sensibilité)

Le rappel mesure la proportion de produits effectivement rachetés que le modèle a réussi à identifier :

$$\text{Recall} = \frac{TP}{TP + FN}$$

Un rappel élevé signifie que peu de produits réellement rachetés sont manqués par le modèle.

4. F1 Score

Le F1 score est la moyenne harmonique entre la précision et le rappel. Il équilibre les deux, particulièrement utile quand elles sont déséquilibrées :

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

5. AUC - ROC (Area Under the Curve)

L'AUC mesure la capacité du modèle à distinguer entre les classes (racheté ou non) pour tous les seuils possibles. Elle est calculée comme l'aire sous la courbe ROC (courbe TPR vs FPR) :

$$\text{AUC} = \int_0^1 \text{TPR}(x) dx$$

où :

- **TPR** = $\frac{TP}{TP+FN}$: taux de vrais positifs,
- **FPR** = $\frac{FP}{FP+TN}$: taux de faux positifs.

Une AUC proche de 1 indique un excellent modèle ; proche de 0.5, il est équivalent au hasard.

6. Log Loss (Perte Logarithmique)

Le log loss évalue la qualité des probabilités prédites, en pénalisant fortement les erreurs confiantes :

$$\text{Log Loss} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

où :

- $y_i \in \{0, 1\}$ est la vraie étiquette,
- p_i est la probabilité prédite pour que $y_i = 1$,
- N est le nombre total d'observations.

Un log loss faible reflète un bon calibrage du modèle.

8.3.2 Régression logistique

Principe :

C'est un modèle de classification binaire qui estime la probabilité qu'un événement se produise (par exemple, un achat), en modélisant une fonction linéaire des variables d'entrée, puis en appliquant une fonction sigmoïde pour transformer le score en probabilité.

Formule :

$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

On prédit pour chaque produit si l'utilisateur va l'acheter (≥ 0.5) ou non (< 0.5), en fonction de ses données historiques.

Avantages :

- Simple à interpréter.
- Rapide à entraîner.

Limites :

- Ne capture pas les relations non linéaires complexes.
- Moins performant si les données ne sont pas bien préparées.

Application :

L'indice de variance d'inflation (VIF pour Variance Inflation Factor) permet de quantifier le degré de multi colinéarité entre une variable explicative et l'ensemble des autres variables du modèle de régression linéaire multiple. Mathématiquement, le VIF associé à une variable explicative X_j est défini par la formule suivante :

$$\text{VIF}(X_j) = \frac{1}{1 - R_j^2}$$

Où R_j^2 est le coefficient de détermination obtenu en régressant X_j sur toutes les autres variables explicatives du modèle. Un VIF proche de 1 indique une absence de colinéarité, tandis qu'un VIF élevé (généralement supérieur à 5 ou 10) révèle une forte redondance de l'information portée par X_j , ce qui peut engendrer une instabilité des coefficients estimés (fortes variances, signes inversés, etc.). Dans notre cas, les variables présentant un VIF élevé ont été examinées de plus près ; certaines ont été supprimées ou combinées afin de réduire la redondance et d'améliorer la fiabilité du modèle. Cette étape est essentielle pour garantir des estimations robustes et interprétables dans un cadre de modélisation prédictive ou explicative.

Table 7: Valeurs du VIF pour chaque variable explicative

Variable	VIF
const	139.642621
up_orders	3.249297
up_first_order	4.037762
up_last_order	∞
up_average_cart_position	1.606657
up_order_rate	3.128689
up_orders_since_last_order	∞
up_order_rate_since_first_order	2.014208
user_orders	∞
user_period	3.364737
user_mean_days_since_prior	2.522818
user_reorder_ratio	2.146413
user_average_basket	1.681758
time_since_last_order	1.398963
future_order_dow	1.003146
future_order_hour_of_day	1.001445
prod_freq	1.857969
prod_avg_position	1.738748
prod_reorder_ratio	5.239718
user_prod_avg_freq	8.115033

Les variables `up_orders_since_last_order`, `up_last_order`, `user_orders`, `prod_reorder_ratio` et `user_prod_avg_freq` présentent des VIF très élevés (notamment infini ou supérieur à 5), indiquant une forte colinéarité avec d'autres variables du modèle. Cela suggère que ces variables sont presque parfaitement prédites par d'autres variables, rendant leur présence redondante et instable dans le modèle. Par conséquent, pour réduire cette colinéarité et améliorer la stabilité des coefficients, il est recommandé de les retirer. Une fois ces variables supprimées, le modèle devrait converger plus facilement, et les coefficients restants devraient être plus fiables et interprétables.

8.3.3 Modèle Logistique

Table 8: Résumé des coefficients du modèle de régression logistique

Variable	Coef	Std Err	z	P> z	[0.025, 0.975]
up_orders	0.0502	0.0	103.032	0.0	[0.049, 0.051]
up_first_order	-0.0019	0.0	-10.462	0.0	[-0.002, -0.002]
up_average_cart_position	-0.0055	0.0	-18.203	0.0	[-0.006, -0.005]
up_order_rate	2.2434	0.012	193.461	0.0	[2.221, 2.266]
up_order_rate_since_first_order	1.5794	0.006	254.343	0.0	[1.567, 1.592]
user_period	-0.0013	2.43e-05	-52.328	0.0	[-0.001, -0.001]
user_mean_days_since_prior	-0.0192	0.0	-63.815	0.0	[-0.020, -0.019]
user_reorder_ratio	0.3053	0.01	30.438	0.0	[0.286, 0.325]
user_average_basket	0.0126	0.0	43.188	0.0	[0.012, 0.013]
time_since_last_order	-0.0066	0.0	-39.568	0.0	[-0.007, -0.006]
future_order_hour_of_day	-0.0406	0.0	-123.981	0.0	[-0.041, -0.040]
prod_freq	1.115e-07	2.02e-08	5.534	0.0	[7.2e-08, 1.51e-07]
prod_avg_position	-0.2876	0.001	-393.91	0.0	[-0.289, -0.286]

Analyse des coefficients et performance du modèle logistique

- **Coefficients** : Les coefficients des variables sont significatifs, avec des valeurs-p proches de zéro (toutes inférieures à 0.05), indiquant que toutes les variables sont significativement associées à la probabilité de ré-achat (variable dépendante).
 - **up_orders** : Un coefficient de 0.0502 signifie qu'une augmentation du nombre de commandes passées augmente légèrement la probabilité de ré-achat.
 - **up_order_rate et up_order_rate_since_first_order** ont des coefficients de 2.2434 et 1.5794, respectivement, ce qui montre que plus le taux de commande est élevé, plus la probabilité de ré-achat augmente fortement.
 - **user_mean_days_since_prior** : Le coefficient de -0.0192 suggère qu'un nombre plus élevé de jours écoulés depuis la dernière commande diminue la probabilité de ré-achat.
 - **prod_avg_position** : Le coefficient de -0.2876 montre que les produits situés plus bas dans la liste des produits (ou dans l'ordre des suggestions) ont une probabilité plus faible d'être achetés à nouveau.

En conclusion, ce modèle logistique semble expliquer de manière significative les comportements d'achat, avec des variables importantes telles que le taux de commande et le temps écoulé depuis la dernière commande. Les résultats montrent des relations fortes entre les comportements d'achat et les caractéristiques des produits et des utilisateurs.

Table 9: Performance de la régression logitistique

Metric	Value
Accuracy	0.9059
Precision	0.5724
Recall	0.1511
F1 Score	0.2391
ROC AUC	0.7839
Log Loss	0.268

- **Accuracy (90.6%)** : Le modèle prédit correctement dans environ 91% des cas. Cela semble très élevé, mais ce score peut être trompeur si les classes sont déséquilibrées (par exemple, peu de cas “recommandés”).
- **Precision (57.2%)** : Lorsqu’il prédit une recommandation (classe positive), il a raison environ 57% du temps. Cela indique que plus de la moitié des prédictions positives sont correctes.
- **Recall (15.1%)** : Le modèle n’arrive à identifier que 15% des vraies recommandations. Cela signifie qu’il rate 85% des cas réellement positifs, ce qui est problématique si l’objectif est de capturer le plus grand nombre possible de ces cas.
- **F1 Score (23.9%)** : Cette mesure équilibre précision et rappel. Le score bas reflète le mauvais rappel et montre que le modèle est peu performant sur les cas positifs.
- **ROC AUC (78.4%)** : Ce score évalue la capacité du modèle à distinguer entre les deux classes, indépendamment d’un seuil. Il est bon (au-dessus de 75%), ce qui signifie que le modèle a un bon pouvoir discriminant.
- **Log Loss (0.268)** : Le modèle est bien calibré en termes de probabilités. Un log loss bas indique que les probabilités prédites sont proches des vraies étiquettes.

Conclusion : Le modèle distingue bien les cas positifs et négatifs (ROC AUC élevé), mais il ne parvient pas à capturer la majorité des cas positifs (recall très faible)

8.3.4 Random Forest

Principe :

C’est un modèle d’ensemble basé sur la construction de plusieurs arbres de décision. Chaque arbre est entraîné sur un sous-échantillon aléatoire du dataset avec un sous-ensemble aléatoire de caractéristiques.

Fonctionnement :

- Chaque arbre vote pour une prédiction.
- La prédiction finale est celle ayant le plus de votes.

On modélise la décision d’achat d’un utilisateur comme un ensemble de conditions sur ses comportements passés. Chaque arbre explore une combinaison différente.

Avantages :

- Très bon compromis entre performance et robustesse.
- Supporte les données bruitées.
- Moins sensible au surapprentissage qu'un arbre unique.
- Fournit une mesure d'importance des variables (utile pour interpréter les résultats).

Limites :

- Moins performant que XGBoost sur des données très structurées avec des interactions complexes.
- Lent sur un très grand ensemble de données.


Application :

Figure 21: Importance des variables Random Forest

Ce graphique à barres révèle l'importance des variables dans un modèle de Forêt Aléatoire, où l'on observe que les caractéristiques liées au taux et au nombre de commandes supplémentaires (`up_order_rate`, `up_order_rate_since_first_order`, `up_orders_since_last_order`) sont les plus influentes pour la prédiction. L'importance des autres variables diminue progressivement, avec des caractéristiques comme le jour et l'heure de la future commande apparaissant comme les moins significatives pour le modèle. En somme, l'historique des ajouts au panier des utilisateurs joue un rôle prédominant dans les prédictions de ce modèle de Forêt Aléatoire.

Table 10: Performance du modèle Random Forest

Performance	Valeur
Accuracy	0.9089
Precision	0.6480
Recall	0.1496
F1 Score	0.2431
ROC AUC	0.8294
Log Loss	0.2478

- **Accuracy (90.89%)** : La précision globale est très bonne, avec près de 91% de prédictions correctes. Comme pour la régression logistique, cela peut refléter un bon comportement global, mais ce n'est pas suffisant si les classes sont déséquilibrées.
- **Precision (64.8%)** : Quand le modèle prédit une recommandation, il a raison près de 65% du temps, ce qui est nettement mieux que la régression logistique (57.2%).
- **Recall (14.96%)** : Le modèle détecte seulement 15% des produits réellement recommandés, ce qui reste très faible, bien que comparable à celui de la régression logistique. Il continue à ignorer une grande partie des vrais cas positifs.
- **F1 Score (24.3%)** : Cet équilibre entre précision et rappel montre une performance modérée sur les cas positifs. Légère amélioration par rapport à la régression logistique.
- **ROC AUC (82.9%)** : Le modèle distingue mieux que la régression logistique les cas positifs et négatifs, ce qui montre un bon pouvoir discriminant.
- **Log Loss (0.248)** : Plus bas que celui de la régression logistique, ce qui signifie que le modèle fournit des probabilités plus fiables.

8.3.5 XGBoost (Extreme Gradient Boosting)

Principe :

C'est un algorithme de boosting basé sur des arbres de décision. Il construit les arbres séquentiellement, en mettant l'accent sur les erreurs commises par les arbres précédents. Chaque nouvel arbre corrige les prédictions des précédents.

Fonctionnement :

- Utilise un objectif différentiable (ex. log-loss).
- Optimisation par descente de gradient.

Il permet de modéliser des comportements d'achat complexes en s'adaptant dynamiquement aux erreurs de prédiction précédentes.

Avantages :

- Très performant pour des problèmes complexes.
- Contrôle précis du surapprentissage grâce à la régularisation.

Limites :

- Plus complexe à configurer (de nombreux hyperparamètres).
- Peut surapprendre si mal réglé.

Application :

Dans le cadre de la sélection de variables, nous avons utilisé l'importance des variables calculée à partir du gain, une mesure intrinsèque à l'algorithme XGBoost. Le gain représente la réduction de l'erreur apportée par un split lorsqu'une variable est utilisée pour diviser un nœud dans un arbre de décision. Plus précisément, à chaque division, le modèle évalue combien la fonction de perte est améliorée, et cette amélioration (le gain) est attribuée à la variable responsable de la division.




Figure 22: *Scores d'importance des variables*

Le graphe d'importance des variables généré par le modèle XGBoost met en évidence les caractéristiques qui ont le plus contribué aux décisions de prédiction. On y observe que les variables les plus influentes sont liées à l'interaction entre l'utilisateur et le produit, telles que `up_order_rate_since_first_order`, `up_orders_since_last_order` ou encore `user_reorder_ratio`. Cela suggère que l'historique d'achat d'un produit par un utilisateur — en particulier la fréquence et la récence des réachats — joue un rôle déterminant dans la prédiction d'un nouveau réachat. Les variables purement descriptives du produit ou de l'utilisateur, comme `prod_avg_position` ou `user_mean_days_since_prior`, apparaissent quant à elles comme moins importantes. Cette hiérarchisation des variables permet non seulement de mieux comprendre le comportement d'achat, mais aussi de guider une éventuelle réduction dimensionnelle du jeu de données pour simplifier et optimiser le modèle.

Table 11: Performance du modèle XGBoost

Métrique	Valeur
Accuracy	0.9097
Precision	0.6350
Recall	0.1770
F1 Score	0.2768
ROC AUC	0.8330
Log Loss	0.2454

- **Accuracy (90.97%)** : Le taux global de bonnes prédictions est très élevé. Cependant, comme toujours en classification déséquilibrée, cette métrique seule ne suffit pas à juger de la qualité du modèle sur les cas positifs.
- **Precision (63.5%)** : Lorsqu'il prédit une recommandation (classe positive), il a raison dans environ deux tiers des cas, ce qui est satisfaisant et montre une bonne fiabilité dans les alertes émises.
- **Recall (17.7%)** : Le modèle identifie environ 18% des cas réellement positifs. Ce score est meilleur que celui obtenu par la régression logistique et les versions précédentes du Random Forest, ce qui montre une meilleure capacité à capter les produits à recommander, bien que beaucoup soient encore ignorés.
- **F1 Score (27.7%)** : Ce compromis entre précision et rappel est le plus élevé des modèles testés jusqu'ici, ce qui reflète une meilleure performance globale sur les cas positifs.
- **ROC AUC (83.3%)** : Le modèle montre un très bon pouvoir discriminant entre classes positives et négatives. C'est une des meilleures performances en AUC parmi les modèles testés.
- **Log Loss (0.245)** : Ce score est le plus bas des modèles évalués jusqu'à présent. Cela signifie que le modèle fournit des probabilités bien calibrées, ce qui est crucial si vous utilisez les scores pour de la priorisation ou des décisions probabilistes.

8.3.6 4. Naive Bayes

Principe :

C'est un modèle probabiliste basé sur le théorème de Bayes, qui calcule la probabilité qu'un événement appartienne à une certaine classe, en supposant que les caractéristiques (features) sont indépendantes les unes des autres.

Formule du théorème de Bayes :

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

Chaque produit est une classe, et les achats précédents de l'utilisateur sont les observations. On estime la probabilité que l'utilisateur achète un produit donné, sachant son historique.

Avantages :

- Très rapide à entraîner.
- Bonne performance sur des données textuelles ou catégoriques.

Limites :

- Hypothèse d'indépendance souvent irréaliste.
- Moins performant sur des données avec corrélation forte entre variables.

Table 12: Performance du modèle Naive Bayes

Métrique	Valeur
Accuracy	0.8859502383378848
Precision	0.3394086297176774
Recall	0.17572339894939223
F1 Score	0.2315602009879789
ROC AUC	0.7254758336706563
Log Loss	0.5895532517022744

Interprétation des performances du modèle Naive Bayes :

- **Accuracy (88.60%)** : Bien que ce taux de bonnes prédictions semble correct, il est nettement inférieur à celui des autres modèles testés (comme la régression logistique ou les forêts aléatoires). Cela suggère que le modèle a plus de mal à bien généraliser sur l'ensemble des données.
- **Precision (33.9%)** : Lorsque le modèle prédit qu'un produit sera recommandé, il se trompe environ deux fois sur trois. Cela montre une faible fiabilité des prédictions positives et un fort taux de faux positifs.
- **Recall (17.6%)** : Le modèle détecte environ 18% des produits effectivement recommandés. Ce rappel est équivalent à celui obtenu avec d'autres modèles, ce qui indique que Naive Bayes n'est pas totalement inefficace pour identifier les vrais cas positifs.
- **F1 Score (23.2%)** : Le compromis entre précision et rappel est inférieur à celui des modèles précédents, ce qui reflète un équilibre global plus faible dans la détection des recommandations pertinentes.
- **ROC AUC (72.5%)** : Ce score indique que le modèle est moins performant pour discriminer entre les classes positives et négatives. Il s'agit du plus faible AUC parmi les modèles testés, ce qui signifie que la probabilité prédite est moins fiable pour séparer les deux classes.
- **Log Loss (0.5895)** : Ce score est le plus élevé jusqu'à présent, traduisant une mauvaise calibration des probabilités. Cela indique que le modèle donne des scores probabilistes peu informatifs, souvent éloignés de la vérité.

Comparaison de modèles :

Table 13: Comparaison des performances des modèles

Métrique	Régression Logistique	Random Forest	XGBoost	Naive Bayes
Accuracy	0.90	0.90	0.90	0.88
Precision	0.57	0.64	0.63	0.33
Recall	0.15	0.14	0.17	0.17
F1 Score	0.23	0.24	0.27	0.23
ROC AUC	0.78	0.82	0.83	0.72
Log Loss	0.26	0.24	0.24	0.58

Afin de sélectionner le modèle le plus performant, plusieurs algorithmes ont été comparés : la régression logistique, Random Forest, XGBoost et Naive Bayes. Bien que l'accuracy soit similaire pour les trois premiers modèles (**0,90**), une analyse plus fine basée sur des métriques complémentaires (**précision**, **rappel**, **F1-score**, **ROC AUC** et **log loss**) permet de mieux distinguer leurs performances. Le modèle **XGBoost** se distingue comme le meilleur compromis global. Il obtient le **F1-score** le plus élevé (**0,27**), indiquant un bon équilibre entre **précision** (**0,63**) et **rappel** (**0,17**), tout en affichant le meilleur score **ROC AUC** (**0,83**), ce qui témoigne d'un excellent pouvoir discriminant. De plus, sa **log loss** (**0,24**) est la plus faible, ex aequo avec **Random Forest**, traduisant une bonne calibration des probabilités. En comparaison, **Naive Bayes** présente des performances nettement inférieures sur l'ensemble des métriques. Ainsi, **XGBoost** a été retenu comme modèle final pour sa capacité à combiner **robustesse**, **performance** et **fiabilité** dans les prédictions.

Conclusion

Ce projet a permis de mener une analyse complète et structurée des comportements d'achat des utilisateurs de la plateforme Instacart. L'approche adoptée s'est appuyée sur plusieurs étapes complémentaires, allant de l'exploration descriptive des données à la modélisation prédictive, en passant par la segmentation des clients et l'analyse des paniers d'achat.

Dans un premier temps, l'analyse descriptive a mis en évidence la domination de certains départements comme les **fruits et légumes**, les **produits laitiers** et les **boissons**, qui concentrent à la fois un volume élevé d'achats et un taux de réachat important. À l'inverse, les rayons comme les **soins personnels** ou l'**épicerie sèche**, bien que riches en diversité, enregistrent des achats moins fréquents. Les habitudes temporelles des utilisateurs ont révélé des pics de commandes le dimanche et le lundi matin, et un comportement d'achat centré autour de 5 à 15 produits par commande, avec un cycle hebdomadaire dominant.

La phase de segmentation, basée sur l'ACP et le clustering K-means, a permis d'identifier trois profils d'utilisateurs : les **clients fidèles et très actifs**, les **acheteurs réguliers modérés**, et les **clients occasionnels**. Cette classification a été statistiquement validée par des tests t de Student et des tailles d'effet (*Cohen's d*), confirmant des différences significatives en termes de fidélité, diversité d'achat et fréquence de commande.

L'analyse des paniers d'achats, réalisée via l'algorithme **Apriori**, a révélé des règles d'association robustes entre certains produits, en particulier autour des **fruits**, **yaourts**, **produits bio** et **paniers sains**. Le filtrage par support et confiance a permis d'identifier des combinaisons produits pertinentes et exploitables pour la recommandation ou le merchandising.

Enfin, la modélisation prédictive a comparé quatre modèles de machine learning pour anticiper les produits susceptibles d'être rachetés. Le modèle **XGBoost** s'est montré le plus performant, avec le meilleur **F1-score** (0.27) et **ROC AUC** (0.83), malgré un rappel encore modeste (17.7 %), reflétant la difficulté du problème dû au déséquilibre des classes.

Perspectives

Plusieurs pistes d'amélioration peuvent être envisagées pour affiner ces résultats :

- **Amélioration du rappel** : intégrer des techniques de gestion du déséquilibre comme le suréchantillonnage (**SMOTE**) ou l'ajustement dynamique des seuils.
- **Enrichissement des données** : inclure des variables contextuelles telles que les **promotions**, la **saisonnalité**, ou les **préférences alimentaires**.
- **Approche séquentielle** : intégrer des modèles séquentiels (**RNN**, **transformers**) pour capturer l'évolution temporelle des comportements.
- **Déploiement opérationnel** : exploiter les règles d'association et les prédictions pour alimenter un moteur de recommandation personnalisé en temps réel.

En somme, cette étude démontre la richesse des enseignements que l'on peut tirer d'une base transactionnelle complexe et souligne le potentiel de la **data science** pour guider les stratégies marketing, améliorer la fidélisation client et optimiser l'expérience d'achat en ligne.

Merci de votre lecture :)